

MATHEUS RAMOS

DESENVOLVEDOR — IA GENERATIVA & GOOGLE CLOUD

Agente LLM conversacional rodando na Google Cloud

CONTATO

-  (44) 99871-8587
-  mathx1celular19@gmail.com
-  linkedin.com/in/matheus-ramos-322644212
-  github.com/MathArmos

COMPETÊNCIAS

IA Generativa & LLMs

- Gemini 2.5 Flash via Vertex AI (keyless/ADC)
- Function calling e Structured Outputs
- Engenharia de prompt · defesa contra prompt injection
- Orquestração de agentes · LangChain
- Observabilidade (LLM tracing LGPD-safe)

Google Cloud & Infraestrutura

- GCP · Vertex AI · IAM / Service Accounts
- Autenticação keyless (ADC)
- Circuit breakers · retry/backoff · rate limiting
- Logging estruturado · fail-fast config
- Redis + BullMQ (filas, workers)

Desenvolvimento

- TypeScript · Node.js · Express
- PostgreSQL + Prisma · Yup · APIs REST
- Arquitetura CSMR · multi-tenant
- Skills, Agents e MCPs (dev assistido por IA)

FORMAÇÃO

- Engenharia de Software — UniCesumar (cursando)
- Curso de Node.js — ONP
- Curso de JavaScript — ONP
- Workshop Dev assistido por IA avançado — Tech Leads Club (Waldemar Neto)
- Análise e Design de Software — ACCION Sistemas (presencial)
- Workshop UX/UI Design — Kacio Felipe
- Inglês (técnico/básico)

FORMAÇÕES EM ANDAMENTO

- Google Cloud ACE (em estudo)
- Google ADK — Agent Development Kit (em estudo)
- Leitura: Arquitetura de Software: as Partes Difíceis — Neal Ford et al.
- Próxima: O Engenheiro de Software com Mentalidade de Produto

INTERESSES

- Aprimorar inglês

PERFIL

Desenvolvedor com pouco mais de 1 ano de experiência e **mentalidade de dono** — cuido do produto como se fosse meu. Construí e mantenho um **agente conversacional LLM implantado na Google Cloud** — atualmente em **treinamento supervisionado com o setor de qualidade** antes de atender os condomínios — usando Vertex AI (Gemini), function calling, structured outputs e padrões de confiabilidade (circuit breakers, retry, rate limiting). Foco em IA generativa aplicada, integrações em nuvem e desenvolvimento assistido por IA.

EXPERIÊNCIA

Guardian — Porteiro Virtual Inteligente (Agente LLM)

Projeto autoral · Implantado na Google Cloud (em treinamento supervisionado)

Agente conversacional que atua como **porteiro virtual via WhatsApp** para uma empresa de portaria remota, **projetado para atender múltiplos condomínios** a partir de um único número central, com meta de **85% de resolução automática**.

Status: implantado e rodando na **Google Cloud**, atualmente em **treinamento supervisionado com o setor de qualidade** — rollout gradual antes de entrar em produção plena nos condomínios.

IA & Google Cloud

- Gemini 2.5 Flash servido via **Vertex AI**, autenticação **keyless/ADC** (sem chave exposta), região `southamerica-east1`
- **Function calling** para pré-cadastro de visitantes, consulta de moradores/dispositivos e abertura de solicitações
- **Structured Outputs** para garantir respostas em JSON parseável no dispatcher de mensagens
- **Defesa contra prompt injection** (delimitação de contexto) validada em auditoria de segurança
- **LLM tracing** (LGPD-safe) para observabilidade do modelo em produção

Confiabilidade / SRE

- **Circuit breakers** para Vertex AI, Meta Cloud API e integrações externas — evita falha em cascata
- **Retry com backoff exponencial** (3 tentativas) nas chamadas externas
- **Rate limiting por telefone** (sliding window em Redis)
- Validação **fail-fast** de variáveis de ambiente no startup

Arquitetura & Backend

- Node.js + TypeScript + Express no padrão **CSMR** (Controller, Service, Models, Repositories) com factories por domínio
- PostgreSQL + **Prisma** + Yup · **multi-tenant** (isolamento por `tenantId` em todas as queries)
- **Redis + BullMQ**: fila assíncrona, deduplicação e workers dedicados
- Integração **Meta Cloud API** (WhatsApp) via webhook com validação **HMAC**
- **Signed URLs keyless** via `iam.signBlob`

Segurança & LGPD

- Autenticação **JWT role-based**, bcrypt, rate limiters
- Auditorias de segurança **OWASP Top 10** por módulo
- Retenção de dados **LGPD** com fila de expiração automática

Testes: suíte Jest cobrindo HMAC, circuit breaker, rate limit e isolamento de tenant — sem dependências externas.

Stack: Node.js · TypeScript · Express · Vertex AI (Gemini 2.5 Flash) · PostgreSQL · Prisma · Redis · BullMQ · Meta Cloud API · Google Cloud